

# Distribución normal multivariada

## Propiedades e inferencias

Mario J. P. López

Departamento de Matemáticas  
Universidad El Bosque

2020

## f.d.p. normal p-variada

Un vector aleatorio  $\mathbf{X}$  ( $p \times 1$ ) tiene distribución normal multivariada, con vector de medias  $\boldsymbol{\mu} \in \mathbb{R}^p$  y matriz de covarianzas  $\Sigma > 0$ , si su f.d.p. está dada por

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad \mathbf{x} \in \mathbb{R}^p,$$

y escribimos  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ . El término

$$\Delta = \left[ (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]^{1/2}$$

se conoce como distancia de Mahalanobis y  $|\Sigma|$  es la varianza generalizada de  $\mathbf{X}$ .

# Función generadora de momentos

f.g.m.

Un vector aleatorio  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$  tiene función generadora de momentos, f.g.m.

$$M_{\mathbf{X}}(\mathbf{t}) := E \left[ \exp(\mathbf{t}^\top \mathbf{X}) \right] = \exp \left( \boldsymbol{\mu}^\top \mathbf{t} + \frac{1}{2} \mathbf{t}^\top \Sigma \mathbf{t} \right),$$

con  $\mathbf{t} \in \mathbb{R}^p$ .

## 1. Combinaciones lineales de v.a. normales multivariadas

- Sea  $\mathbf{a}$  un vector  $(p \times 1)$  de constantes y  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , entonces  $\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top \Sigma \mathbf{a})$ .
- Si  $A$  es una matriz  $(q \times p)$  de constantes, de rango  $q \leq p$ , y  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , entonces  $A\mathbf{X} \sim N_q(A\boldsymbol{\mu}, A\Sigma A^\top)$ .

## 2. Estandarización multivariada

Dado  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , un vector estandarizado  $\mathbf{Z}$ , con distribución  $N_p(\mathbf{0}, I_p)$ , se puede obtener como

$$\mathbf{Z} = (\Gamma^\top)^{-1}(\mathbf{X} - \boldsymbol{\mu}),$$

donde  $\Sigma = \Gamma^\top \Gamma$ .

## 3. Normalidad de distribuciones marginales

Sean  $\mathbf{X}_1 = (X_1, \dots, X_r)^\top$  y  $\mathbf{X}_2 = (X_{r+1}, \dots, X_p)^\top$ , con  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$  y

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

entonces  $\mathbf{X}_1 \sim N_r(\boldsymbol{\mu}_1, \Sigma_{11})$ .

- En particular,  $X_j \sim N(\mu_j, \sigma_j^2)$ ,  $j = 1, \dots, p$
- lo contrario no es necesariamente cierto

## 4. Independencia

Sean  $\mathbf{X}$  ( $p \times 1$ ) y  $\mathbf{Y}$  ( $q \times 1$ ), tal que

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix} \sim N_{p+q} \left( \begin{pmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{pmatrix} \right),$$

entonces los sub-vectores  $\mathbf{X}$  y  $\mathbf{Y}$  son independientes si  $\Sigma_{xy} = \mathbf{0}$ .

## 5. Distribución condicional

En la propiedad anterior, si  $\mathbf{X}$  y  $\mathbf{Y}$  no son independientes, entonces  $\Sigma_{xy} \neq \mathbf{0}$  y la distribución condicional de  $\mathbf{X}$  dado  $\mathbf{Y}$  es normal multivariada con

$$E[\mathbf{Y} | \mathbf{X}] = \mu_y + \Sigma_{yx} \Sigma_{xx}^{-1} (\mathbf{X} - \mu_x)$$

$$C[\mathbf{Y} | \mathbf{X}] = \Sigma_{yy} - \Sigma_{yx} \Sigma_{xx}^{-1} \Sigma_{xy}$$

## 6. Distribución $\chi^2$

Si  $\mathbf{X} \sim N_p(\mu, \Sigma)$  y  $\mathbf{Z} = (\Gamma^\top)^{-1} (\mathbf{X} - \mu)$  tal que  $\mathbf{Z} \sim N_p(\mathbf{0}, I_p)$  entonces

$$\mathbf{Z}^\top \mathbf{Z} = (\mathbf{x} - \mu)^\top \Sigma^{-1} (\mathbf{x} - \mu) \sim \chi_p^2$$

## 7. Distribución de la suma de dos sub-vectores

Sean  $\mathbf{X}$  ( $p \times 1$ ) y  $\mathbf{Y}$  ( $p \times 1$ ), independientes, tal que

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix} \sim N_{2p} \left( \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \Sigma_{xx} & \mathbf{0} \\ \mathbf{0} & \Sigma_{yy} \end{pmatrix} \right),$$

entonces

$$\mathbf{X} \pm \mathbf{Y} \sim N_p \left( \mu_x \pm \mu_y, \Sigma_{xx} + \Sigma_{yy} \right)$$



## Función de (log)verosimilitud

Sean  $\mathbf{X}_1, \dots, \mathbf{X}_n$  una muestra aleatoria de una v.a.  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , la función de máxima verosimilitud de la muestra está dada por

$$\begin{aligned} L(\mathbf{X}_1, \dots, \mathbf{X}_n; \boldsymbol{\mu}, \Sigma) &= \prod_{i=1}^n f_{\mathbf{X}_i}(\mathbf{x}_i) \\ &= \prod_{i=1}^n \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right\} \\ &= \frac{1}{(2\pi)^{np/2} |\Sigma|^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right\} \end{aligned}$$

y la función de log-verosimilitud

$$\ell(\mathbf{X}_1, \dots, \mathbf{X}_n; \boldsymbol{\mu}, \Sigma) = -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x}_i - \boldsymbol{\mu})$$

## MLE

Los estimadores de máxima verosimilitud de  $\boldsymbol{\mu}$  y  $\boldsymbol{\Sigma}$  son

$$\hat{\boldsymbol{\mu}} = \bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\hat{\boldsymbol{\Sigma}} = S_n = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}}) (\mathbf{x}_i - \bar{\mathbf{X}})^{\top}$$

respectivamente.

## Distribución de $\bar{\mathbf{X}}$

- Cuando  $\mathbf{X}_1, \dots, \mathbf{X}_n$  es una muestra aleatoria de una v.a.  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ , entonces  $\bar{\mathbf{X}} \sim N(\boldsymbol{\mu}, \Sigma/n)$
- Cuando  $\mathbf{X}_1, \dots, \mathbf{X}_n$  es una muestra aleatoria de una distribución no normal con vector de medias  $\boldsymbol{\mu}$  y matriz de covarianzas  $\Sigma$ , entonces conforme  $n \rightarrow \infty$ ,  $\bar{\mathbf{X}}$  tiene una distribución aproximada  $N_p(\boldsymbol{\mu}, \Sigma)$ . Este resultado se conoce como el teorema del límite central multivariado. En particular

$$\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim N(\mathbf{0}, \Sigma)$$

conforme  $n \rightarrow \infty$ .

## Distribución Wishart

Una matriz aleatoria  $\mathbf{W}$  ( $p \times p$ ), definida positiva, tiene una distribución Wishart  $\mathbf{W} \sim W_p(n, V)$  con parámetro  $V > 0$ , ( $p \times p$ ) y grados de libertad  $n > p - 1$  si su f.d.p. está dada por

$$f_{\mathbf{W}}(\mathbf{w}) = \frac{|\mathbf{w}|^{(n-p-1)/2} e^{-\text{tr}(V^{-1}\mathbf{w})/2}}{2^{np/2} |V|^{n/2} \Gamma_p\left(\frac{n}{2}\right)},$$

donde  $\Gamma(\cdot)$  es la función gama multivariada.

## Distribución de $S_{n-1}$

- La v.a.

$$W = \sum_{i=1}^n (\mathbf{X}_i - \boldsymbol{\mu})(\mathbf{X}_i - \boldsymbol{\mu})^\top$$

tiene distribución  $W_p(n, \Sigma)$

- La v.a.

$$W = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{X}})(\mathbf{x}_i - \bar{\mathbf{X}})^\top = (n-1) S_{n-1}$$

tiene distribución  $W_p(n-1, \Sigma)$ .

- Se puede demostrar además que  $\bar{\mathbf{X}}$  y  $S_n$  son estadísticamente independientes.

## *q-q plot* univariado

- Sean  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$  las estadísticas de orden de una m.a.
- Encontrar los valores  $q_i$  tal que  $\Phi(q_i) = P(Z \leq q_i) = \frac{i-0.5}{n}$
- Graficar la nube de puntos conformada por las parejas  $(q_i, X_{(i)})$
- Agregar la línea  $X_{(i)} = a + bq_i$  que “mejor” se ajusta a la nube de puntos.

## *q-q plot* multivariado

- Sea  $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$  una m.a. de v.a.  $p$ -variadas.
- Si  $\mathbf{X}_i \sim N_p(\boldsymbol{\mu}, \Sigma)$ ,  $i = 1, \dots, n$ , entonces

$$u_i = \frac{nD_i^2}{(n-1)^2} \sim \text{Beta}\left(\frac{p}{2}, \frac{n-p-1}{2}\right)$$

con

$$D_i = \left(\mathbf{X}_i - \bar{\mathbf{X}}\right)^{\top} S_{n-1}^{-1} \left(\mathbf{X}_i - \bar{\mathbf{X}}\right)$$

## *q-q plot* multivariado

- Calcular los cuantiles de la distribución beta,  $v_i$ ,  $i = 1, \dots, n$ , como solución a

$$\int_0^{v_i} \frac{\Gamma\left(\frac{n-1}{2}\right)}{\Gamma\left(\frac{p}{2}\right) \Gamma\left(\frac{n-p-1}{2}\right)} y^{\frac{p}{2}-1} (1-y)^{\frac{n-p-1}{2}-1} dy = \frac{i-a}{n-a-b+1}$$

con  $a = \frac{(p-2)}{2p}$  y  $b = \frac{n-p-3}{2(n-p-1)}$ .

- Graficar la nube de puntos  $(v_i, u_{(i)})$
- Agregar la línea  $u_{(i)} = a + bv_i$ .



## Test de Mardia

Se basa en la asimetría y la curtosis de poblaciones normales multivariadas

$$\beta_{1,p} = E \left[ (\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{X} - \boldsymbol{\mu}) \right]^3 = 0$$

$$\beta_{2,p} = E \left[ (\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{X} - \boldsymbol{\mu}) \right]^2 = p(p+2)$$

los cuales se pueden estimar como

$$\hat{\beta}_{1,p} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n g_{ij}^3, \quad \hat{\beta}_{2,p} = \frac{1}{n} \sum_{i=1}^n g_{ii}^2$$

$$\text{con } g_{ij} = \left( \mathbf{x}_i - \bar{\mathbf{X}} \right)^\top S_n^{-1} \left( \mathbf{x}_j - \bar{\mathbf{X}} \right).$$

## *Test de Mardia*

Luego, se calculan las estadísticas

$$Z_1 = \frac{(p+1)(n+1)(n+3)}{6[(p+1)(n+1)-6]} \hat{\beta}_{1,p} \sim \chi^2_{p(p+1)(p+2)/6}$$

$$Z_2 = \frac{\hat{\beta}_{2,p} - p(p+2)}{\sqrt{8p(p+2)/n}} \sim N(0,1)$$

Así, se rechaza la hipótesis de normalidad multivariada

- en términos de asimetría si  $Z_1 \geq \chi^2_{0.05, p(p+1)(p+2)/6}$
- en términos de curtosis si  $|Z_2| \geq Z_{0.05}$

## Detectando *outliers*

Un simple procedimiento para detectar *outliers* multivariados consiste en calcular la distancia de Mahalanobis muestral para cada individuo  $i$ -ésimo,

$$MD_i = \left[ \left( \mathbf{x}_i - \bar{\mathbf{x}} \right)^\top S_n^{-1} \left( \mathbf{x}_i - \bar{\mathbf{x}} \right) \right]^{1/2},$$

y compararla con  $\chi_{p,0.975}^2$ .

## *Para $\mu$ con $\Sigma$ conocida*

- Se desea probar  $H_0 : \mu = \mu_0$  contra  $H_1 : \mu \neq \mu_0$ , dada una m.a. de una  $N(\mu, \Sigma)$ .
- Estadístico de prueba:

$$Z^2 = n \left( \bar{\mathbf{X}} - \mu_0 \right)^\top \Sigma^{-1} \left( \bar{\mathbf{X}} - \mu_0 \right)$$

que bajo  $H_0$  sigue una distribución  $\chi_p^2$ .

- Rechazamos  $H_0$  si  $Z^2 > \chi_{\alpha, p}^2$

## *Para $\mu$ con $\Sigma$ desconocida*

- Se desea probar  $H_0 : \mu = \mu_0$  contra  $H_1 : \mu \neq \mu_0$ , dada una m.a. de una  $N(\mu, \Sigma)$ .
- Estadístico de prueba:

$$T^2 = n \left( \bar{\mathbf{X}} - \mu_0 \right)^\top S_{n-1}^{-1} \left( \bar{\mathbf{X}} - \mu_0 \right)$$

que bajo  $H_0$  sigue una distribución  $T_{p,n-1}^2$ .

- Rechazamos  $H_0$  si  $T^2 > T_{\alpha,p,n-1}^2$ .
- Tener en cuenta que si  $w \sim T_{p,m}^2$  entonces

$$\frac{m-p+1}{pm} w \sim F_{p,m-p+1}$$

*Para  $\mu_1 - \mu_2$  con  $\Sigma_1 = \Sigma_2$  desconocidas*

- Se desea probar  $H_0 : \mu_1 = \mu_2$  contra  $H_1 : \mu_1 \neq \mu_2$ , dadas un par de m.a. de una  $N(\mu_1, \Sigma)$  y una  $N(\mu_2, \Sigma)$ .
- Estadístico de prueba:

$$T^2 = \frac{n_1 n_2}{n_1 + n_2} \left( \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \right)^\top S_c^{-1} \left( \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \right)$$

que bajo  $H_0$  sigue una distribución  $T_{p, n_1+n_2-2}^2$ .

- Rechazamos  $H_0$  si  $T^2 > T_{\alpha, p, n_1+n_2-2}^2$ .
- Donde

$$S_c = \frac{(n_1 - 1) S_1 + (n_2 - 1) S_2}{n_1 + n_2 - 2}$$

## *Para $\mu_1 - \mu_2$ con $\Sigma_1 \neq \Sigma_2$ desconocidas*

- Se desea probar  $H_0 : \mu_1 = \mu_2$  contra  $H_1 : \mu_1 \neq \mu_2$ , dadas un par de m.a. de una  $N(\mu_1, \Sigma_1)$  y una  $N(\mu_2, \Sigma_2)$ .
- Estadístico de prueba:

$$T^2 = \left( \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \right)^\top \left[ \frac{S_1}{n_1} + \frac{S_2}{n_2} \right]^{-1} \left( \bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \right)$$

que bajo  $H_0$  sigue una distribución  $\chi_p^2$ .

- Rechazamos  $H_0$  si  $T^2 > T_{\alpha, p}^2$ .

## Homogeneidad de matrices de covarianza

- Se desea probar  $H_0 : \Sigma_1 = \Sigma_2 = \dots = \Sigma_k$  contra  $H_1 : \Sigma_i \neq \Sigma_j$ ,  $i \neq j$ , dadas  $k$  m.a. de  $N(\mu_i, \Sigma_i)$ .
- Prueba de *Bartlett*: Se basa en la estadística

$$MC^{-1} \sim \chi^2_{(k-1)(p+1)p/2}$$

donde

$$C^{-1} = 1 - \frac{2p^2 + 3p - 1}{6(p+1)(k-1)} \left( \sum_{i=1}^k (n_i - 1)^{-1} - \left( \sum_{i=1}^k (n_i - 1) \right)^{-1} \right)$$
$$M = \sum_{i=1}^k (n_i - 1) \ln |S_c| - \sum_{i=1}^k (n_i - 1) \ln |S_i|$$





Rencher, A.

*Methods of Multivariate Analysis.*

2nd ed. Willey, 2002.